Prédiction de la performance des étudiants par des modèles de régression

Es-sabbar Ismail
Étudiant en Intelligence Artificielle et Applications
Faculté Polydisciplinaire Ouarzazate
Université Ibn Zohr
Ouarzazate, Morocco
essabbarismail52@gmail.com

***Abstract*—Dans ce travail, nous appliquons plusieurs modèles de machine learning pour prédire la note finale des étudiants (G3). Nous utilisons différentes techniques de prétraitement et comparons les performances de plusieurs modèles. Les résultats montrent que l'arbre de décision est le modèle le plus performant.**

***Index Terms*—Machine Learning, Régression, Student Performance, Decision Tree**

I. Introduction

La prédiction de la performance des étudiants est un problème important dans le domaine de l'éducation. Elle permet de mieux comprendre les facteurs qui influencent les résultats scolaires. Dans ce travail, nous utilisons des modèles de machine learning pour prédire la note finale G3 à partir de plusieurs variables.

II. État de l'art

Plusieurs modèles sont utilisés en machine learning pour la prédiction.

La régression linéaire est simple mais suppose une relation linéaire. Les arbres de décision sont faciles à comprendre et capables de modéliser des relations non linéaires. Random Forest améliore la performance en combinant plusieurs arbres. SVR est puissant mais dépend fortement des paramètres.

III. Dataset

Le dataset utilisé contient des informations sur les étudiants telles que G1, G2, l'âge, le sexe et les absences. La variable cible est G3, qui représente la note finale de l'étudiant. Ce dataset permet d'analyser les facteurs qui influencent la performance scolaire et d'identifier les variables les plus importantes pour la prédiction.

IV. Analyse exploratoire des données

A. Histogramme

Les histogrammes permettent d'observer la distribution des variables numériques. On remarque que certaines variables sont concentrées autour de certaines valeurs, ce qui montre que les données ne suivent pas toujours une distribution normale.

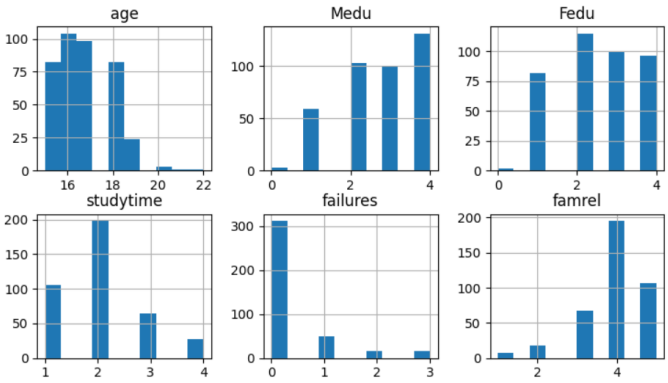

Fig. 1. Distribution des variables

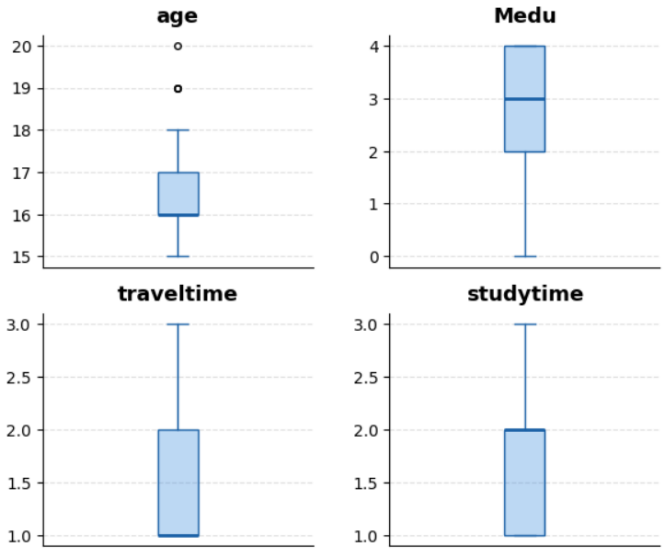

Fig. 2. Détection des valeurs aberrantes

B. Boxplot

Les boxplots permettent de détecter les valeurs aberrantes. On observe la présence de valeurs extrêmes dans certaines variables, ce qui peut influencer les performances des modèles.

C. Matrice de corrélation

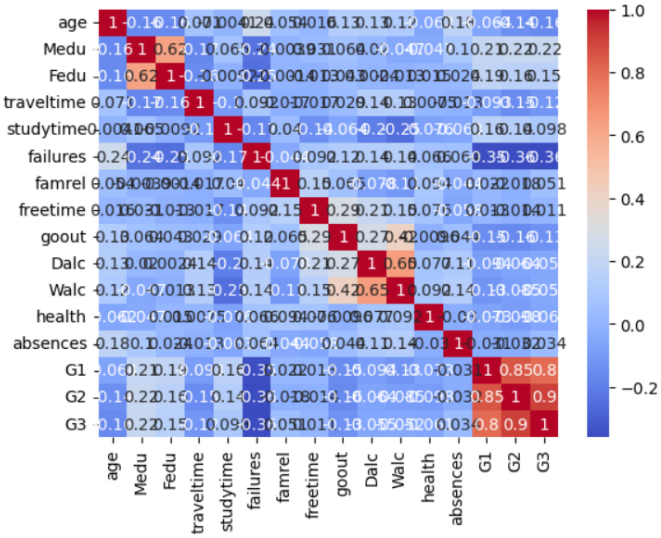

Fig. 3. Corrélation entre les variables

La matrice de corrélation montre les relations entre les variables. On observe que G1 et G2 sont fortement corrélées avec G3, ce qui signifie qu'elles influencent fortement la prédiction.

V. Prétraitement des données

Les variables catégorielles ont été transformées avec One-Hot Encoding. Une standardisation a été appliquée pour les modèles sensibles comme SVR et la régression linéaire. Les valeurs aberrantes ont été supprimées avec la méthode IQR.

VI. Modèles utilisés

Dans ce travail, nous avons utilisé plusieurs modèles de régression, notamment la régression linéaire, Decision Tree, Random Forest et SVR.

VII. Application

L'implémentation a été réalisée en Python avec la bibliothèque scikit-learn. Les données ont été divisées en données d'entraînement et de test. Chaque modèle a été entraîné puis évalué avec différentes métriques.

VIII. Résultats expérimentaux

Cette figure montre la comparaison des performances des modèles. On remarque que l'arbre de décision donne les meilleurs résultats avec un score R2 élevé. Le modèle Random Forest est également performant. La régression linéaire donne des résultats acceptables, tandis que le modèle SVR est le moins performant.

```
---- Linear Regression ----
MSE: 2.2043972043127016
RMSE: 1.4847212547521174
MAE: 0.9889415932251956
R2: 0.8187885745636069
MedAE: 0.6019277398823846
Explained Variance: 0.8239020360460756

---- Random Forest ----
MSE: 1.5524127659574463
RMSE: 1.245958573130522
MAE: 0.7034042553191489
R2: 0.8723846457278953
MedAE: 0.5199999999999996
Explained Variance: 0.872384883894016

---- Decision Tree ----
MSE: 1.4680851063829787
RMSE: 1.211645619140753
MAE: 0.7446808510638298
R2: 0.8793167609407562
MedAE: 1.0
Explained Variance: 0.880247097350402

---- SVR ----
MSE: 5.998644078033919
RMSE: 2.4492129507321163
MAE: 1.6058919414425832
R2: 0.5068843119835917
MedAE: 1.0344999440259652
Explained Variance: 0.5101924075662871
```

Fig. 4. Comparaison des modèles

IX. Discussion

Les modèles basés sur les arbres sont plus adaptés à ce dataset car ils capturent les relations non linéaires. Le modèle Random Forest est plus robuste, mais l'arbre de décision donne de meilleurs résultats dans ce cas. Le scaling améliore les performances des modèles comme SVR.

X. Conclusion

Dans ce travail, nous avons comparé plusieurs modèles pour prédire la performance des étudiants. Les résultats montrent que l'arbre de décision est le modèle le plus performant. Comme perspective, nous pouvons améliorer les résultats en utilisant l'optimisation des hyperparamètres.

References

[1] Scikit-learn, "Machine Learning in Python", Available: https://scikit-learn.org/

[2] UCI Machine Learning Repository, "Student Performance Dataset", Available: https://archive.ics.uci.edu/