Prédiction de la performance des étudiants par des modèles de régression

Es-sabbar Ismail
Étudiant en Intelligence Artificielle et Applications
Faculté Polydisciplinaire Ouarzazate
Université Ibn Zohr
Ouarzazate, Morocco
i.es-sabbar@gmail.com

***Abstract*—La prédiction de la performance académique des étudiants constitue un sujet important dans le domaine de l'intelligence artificielle et de l'analyse des données éducatives. L'objectif principal de ce travail est de comparer plusieurs modèles de régression afin de prédire la note finale des étudiants (G3) à partir de différentes variables académiques et sociales. Le dataset utilisé contient des informations telles que les notes intermédiaires (G1 et G2), l'âge, le sexe, les absences et d'autres caractéristiques liées au contexte scolaire des étudiants.**

Avant l'entraînement des modèles, plusieurs techniques de prétraitement ont été appliquées, notamment l'encodage des variables catégorielles, la standardisation des données et la suppression des valeurs aberrantes. Plusieurs modèles de machine learning ont ensuite été implémentés et comparés, tels que la régression linéaire, Decision Tree, Random Forest et Support Vector Regression (SVR).

Les performances des modèles ont été évaluées à l'aide de différentes métriques d'évaluation telles que l'erreur absolue moyenne (MAE), l'erreur quadratique moyenne (RMSE) et le score de précision des modèles. Les résultats expérimentaux montrent que les modèles basés sur les arbres offrent les meilleures performances sur ce dataset, en particulier l'arbre de décision qui obtient le score le plus élevé. Cette étude montre également l'importance du prétraitement des données dans l'amélioration des performances des modèles prédictifs.

***Index Terms*—Machine Learning, Régression, Student Performance, Decision Tree**

I. Introduction

L'intelligence artificielle et le machine learning connaissent aujourd'hui un développement important dans plusieurs domaines, notamment dans le secteur de l'éducation. Grâce à l'analyse automatique des données, ces technologies permettent d'extraire des informations utiles et de construire des modèles capables de prédire différents phénomènes complexes.

Dans le domaine éducatif, la prédiction de la performance académique des étudiants représente un sujet de recherche important. Elle permet d'identifier les facteurs influençant les résultats scolaires et d'aider les établissements à détecter les étudiants en difficulté dès les premières étapes de leur parcours académique. Cette capacité prédictive peut contribuer à améliorer les stratégies pédagogiques et à proposer un accompagnement adapté afin de réduire le risque d'échec scolaire.

Les données académiques contiennent généralement plusieurs variables explicatives, telles que les notes intermédiaires, les absences, le contexte familial, l'âge et d'autres caractéristiques sociales ou scolaires. L'analyse de ces données par des modèles de machine learning permet d'identifier les relations entre ces variables et la performance finale des étudiants.

Plusieurs travaux de recherche ont montré l'efficacité de différentes méthodes de régression pour résoudre ce type de problème, notamment la régression linéaire, les arbres de décision, Random Forest ainsi que Support Vector Regression (SVR). Toutefois, les performances de ces modèles varient selon la nature du dataset et les techniques de prétraitement appliquées.

L'objectif principal de ce travail est de comparer plusieurs modèles de régression pour prédire la note finale des étudiants (G3) à partir d'un dataset éducatif. Plusieurs étapes ont été réalisées, notamment l'analyse exploratoire des données, le prétraitement, l'entraînement des modèles et l'évaluation de leurs performances à l'aide de différentes métriques.

Le reste de cet article est organisé comme suit : la section suivante présente l'état de l'art, puis la méthodologie adoptée ainsi que les techniques de prétraitement appliquées. Ensuite, les résultats expérimentaux sont présentés et discutés avant de conclure avec les perspectives futures.

II. État de l'art

La prédiction de la performance académique des étudiants est devenue un domaine de recherche important dans le cadre de l'analyse des données éducatives et du machine learning. Plusieurs chercheurs ont proposé différentes approches afin d'identifier les facteurs influençant les résultats scolaires et de construire des modèles capables de prédire les performances des étudiants avec une bonne précision.

Parmi les modèles les plus utilisés dans les travaux de recherche, la régression linéaire occupe une place importante grâce à sa simplicité et sa facilité d'interprétation. Ce modèle cherche à établir une relation linéaire entre les variables explicatives et la variable cible. Il est souvent utilisé comme modèle de base dans les problèmes de régression. Cependant, ses performances diminuent lorsque les relations entre les variables deviennent complexes ou non linéaires.

Les arbres de décision (Decision Tree) représentent également une méthode très populaire dans le domaine du machine learning. Ce modèle construit une structure arborescente permettant de prendre des décisions à partir des caractéristiques des données. Les arbres de décision sont faciles à comprendre et capables de modéliser des relations non linéaires. Toutefois, ils peuvent souffrir du problème d'overfitting lorsque l'arbre devient très profond.

Pour améliorer les performances des arbres de décision, plusieurs chercheurs utilisent Random Forest, qui est une méthode d'ensemble basée sur la combinaison de plusieurs arbres de décision. Cette approche permet de réduire le surapprentissage et d'améliorer la capacité de généralisation du modèle. Random Forest est particulièrement efficace sur les datasets complexes contenant plusieurs variables.

Le modèle Support Vector Regression (SVR) est également utilisé dans les problèmes de prédiction. Ce modèle repose sur le principe des machines à vecteurs de support et cherche à minimiser les erreurs de prédiction tout en maximisant la marge entre les données. SVR peut produire de bonnes performances, mais il nécessite un choix approprié des hyperparamètres et demande généralement un temps d'entraînement plus important.

Plusieurs études ont appliqué ces techniques pour prédire les performances académiques des étudiants. Certaines recherches montrent que les modèles basés sur les arbres, comme Decision Tree et Random Forest, obtiennent souvent de meilleurs résultats grâce à leur capacité à capturer les relations complexes entre les variables éducatives. D'autres travaux soulignent également l'importance des étapes de prétraitement, telles que la normalisation, l'encodage des variables catégorielles et la suppression des valeurs aberrantes, afin d'améliorer les performances des modèles prédictifs.

Dans ce travail, nous proposons une comparaison entre plusieurs modèles de régression appliqués à un dataset éducatif afin d'identifier le modèle le plus performant pour la prédiction de la note finale des étudiants.

III. Méthodologie

Cette section décrit les différentes étapes suivies pour construire et évaluer les modèles de machine learning utilisés dans ce travail. La méthodologie est composée de quatre étapes principales : la description du dataset, le prétraitement des données, le choix des modèles ainsi qu'un schéma global du processus.

A. Dataset

Le dataset utilisé dans cette étude provient du *UCI Machine Learning Repository* et est largement utilisé dans les travaux de prédiction de la performance académique des étudiants. Il contient des informations académiques, personnelles et sociales sur les étudiants.

Les principales variables incluent les notes intermédiaires (G1 et G2), l'âge, le sexe, le temps d'étude, les absences ainsi que d'autres facteurs liés au contexte scolaire. La variable cible du modèle est G3, qui représente la note finale de l'étudiant.

Dalc	Walc	health	absences	G1	G2	G3
395.000000	395.000000	395.000000	395.000000	395.000000	395.000000	395.000000
1.481013	2.291139	3.554430	5.708861	10.908861	10.713924	10.415190
0.890741	1.287897	1.390303	8.003096	3.319195	3.761505	4.581443
1.000000	1.000000	1.000000	0.000000	3.000000	0.000000	0.000000
1.000000	1.000000	3.000000	0.000000	8.000000	9.000000	8.000000
1.000000	2.000000	4.000000	4.000000	11.000000	11.000000	11.000000
2.000000	3.000000	5.000000	8.000000	13.000000	13.000000	14.000000
5.000000	5.000000	5.000000	75.000000	19.000000	19.000000	20.000000

Fig. 1. Aperçu du dataset utilisé

B. Prétraitement des données

Le prétraitement des données est une étape essentielle pour améliorer la qualité des modèles de machine learning. Dans ce travail, plusieurs techniques ont été appliquées :

- Encodage des variables catégorielles à l'aide de One-Hot Encoding.
- Normalisation et standardisation des variables numériques pour uniformiser les échelles.
- Traitement des valeurs aberrantes afin de réduire leur impact sur les modèles.
- Division du dataset en ensemble d'entraînement et ensemble de test.

Ces étapes permettent d'améliorer la stabilité et la performance des modèles utilisés.

C. Choix des modèles

Plusieurs modèles de régression ont été sélectionnés afin de comparer leurs performances sur le même dataset. Les modèles utilisés sont les suivants :

- Régression Linéaire
- Decision Tree Regressor
- Random Forest Regressor
- Support Vector Regression (SVR)

Ces modèles ont été choisis car ils représentent différentes approches du machine learning, allant des méthodes simples et interprétables aux méthodes plus complexes et robustes.

D. Schéma du processus

Le processus global de la méthodologie est illustré comme suit :

Dataset $\rightarrow$ **Prétraitement** $\rightarrow$ **Entraînement des modèles** $\rightarrow$ **Évaluation des performances**

Ce schéma permet de résumer les différentes étapes suivies dans ce travail, depuis la préparation des données jusqu'à l'évaluation finale des modèles.

IV. Application

A. Implémentation

L'implémentation a été réalisée en suivant un pipeline de machine learning comprenant le chargement des données, le prétraitement, l'entraînement des modèles et leur évaluation.

Après préparation des données, plusieurs modèles de régression ont été entraînés et testés sur l'ensemble de test.

Les performances des modèles ont été évaluées à l'aide de métriques telles que R^2, MAE et RMSE afin de comparer leur efficacité.

B. Outils utilisés

Ce travail a été réalisé en langage Python à l'aide de plusieurs bibliothèques :

- Pandas pour la manipulation des données
- NumPy pour les calculs numériques
- Matplotlib et Seaborn pour la visualisation
- Scikit-learn pour les modèles de machine learning

C. Imports Python utilisés

Les principales bibliothèques utilisées dans l'implémentation sont les suivantes :

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.tree import DecisionTreeRegressor
from sklearn.svm import SVR
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from sklearn.metrics import median_absolute_error, explained_variance_score
```

Fig. 2. Détection des valeurs aberrantes

V. Analyse exploratoire des données

L'analyse exploratoire des données (EDA) constitue une étape essentielle dans tout projet de machine learning. Elle permet de mieux comprendre la structure du dataset, la distribution des variables ainsi que les relations entre celles-ci et la variable cible.

A. Histogramme

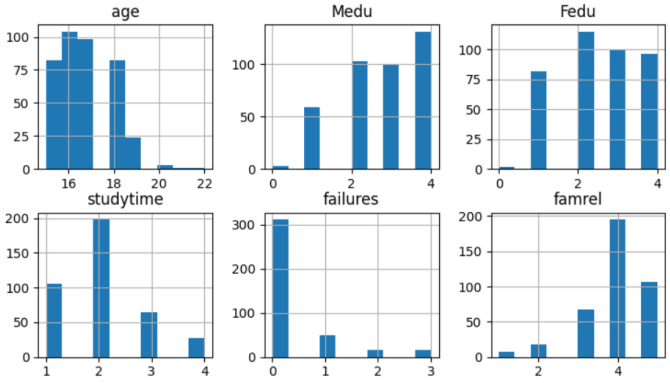

Fig. 3. Distribution des variables

Les histogrammes permettent d'observer la distribution des variables numériques. On remarque que certaines variables sont concentrées autour de certaines valeurs, ce qui indique que les données ne suivent pas toujours une distribution normale. Cette observation est importante car elle influence le choix des modèles et des techniques de prétraitement.

B. Boxplot

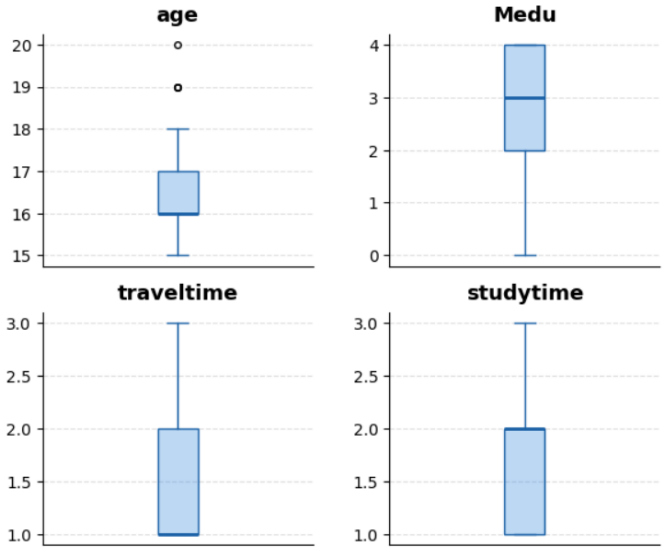

Fig. 4. Détection des valeurs aberrantes

Les boxplots permettent d'identifier les valeurs aberrantes (outliers) présentes dans le dataset. On observe la présence de plusieurs valeurs extrêmes dans certaines variables. Ces valeurs peuvent affecter négativement les performances des modèles de machine learning, d'où l'importance de les traiter lors du prétraitement.

C. Matrice de corrélation

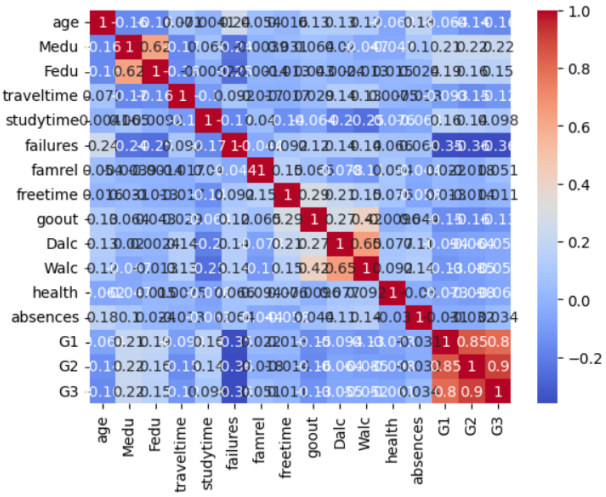

Fig. 5. Corrélation entre les variables

La matrice de corrélation permet d'analyser les relations entre les variables. On remarque une forte corrélation entre G1 et G2 avec la variable cible G3, ce qui indique que les notes précédentes jouent un rôle important dans la prédiction de la performance finale. Cette information est utile pour comprendre l'importance des variables dans le modèle.

VI. Prétraitement des données

Le prétraitement des données est une étape fondamentale dans tout projet de machine learning, car il permet d'améliorer la qualité des données et d'optimiser les performances des modèles.

Dans ce travail, plusieurs étapes de prétraitement ont été appliquées sur le dataset afin de le rendre exploitable par les algorithmes de régression.

A. Gestion des valeurs manquantes

Dans un premier temps, les données ont été vérifiées afin d'identifier la présence de valeurs manquantes. Lorsque cela était nécessaire, ces valeurs ont été traitées soit par suppression, soit par imputation selon la nature de la variable.

absences	0
G1	0
G2	0
G3	0
school_MS	0
sex_M	0
address_U	0
famsize_LE3	0
Pstatus_T	0
Mjob_health	0
Mjob_other	0
Mjob_services	0
Mjob_teacher	0

Fig. 6. Gestion des valeurs manquantes

B. Encodage des variables catégorielles

Les variables catégorielles telles que le sexe ou certaines caractéristiques sociales ont été transformées en variables numériques à l'aide de la technique *One-Hot Encoding*. Cela permet aux modèles de machine learning de les exploiter correctement.

C. Normalisation des données

Une normalisation des variables numériques a été appliquée afin d'uniformiser les échelles des différentes caractéristiques. Cette étape est particulièrement importante pour les modèles sensibles à l'échelle comme la régression linéaire et SVR.

D. Traitement des valeurs aberrantes

Les valeurs aberrantes détectées lors de l'analyse exploratoire ont été traitées afin de limiter leur impact sur les performances des modèles. Cette étape contribue à améliorer la robustesse des prédictions.

E. Séparation des données

Enfin, le dataset a été divisé en deux ensembles : un ensemble d'entraînement et un ensemble de test. Cette séparation permet d'évaluer les modèles sur des données non vues afin de mesurer leur capacité de généralisation.

VII. Modèles utilisés

Dans ce travail, plusieurs modèles de régression issus du machine learning ont été utilisés afin de prédire la variable cible G3 et comparer leurs performances.

- **Régression Linéaire** : modèle simple qui suppose une relation linéaire entre les variables explicatives et la variable cible. Il est facile à interpréter mais limité pour les relations complexes.
- **Decision Tree Regressor** : modèle basé sur une structure arborescente permettant de diviser les données en fonction de règles de décision. Il peut capturer des relations non linéaires mais peut souffrir d'overfitting.
- **Random Forest Regressor** : méthode d'ensemble combinant plusieurs arbres de décision afin d'améliorer la précision et réduire le surapprentissage.
- **Support Vector Regression (SVR)** : modèle basé sur les machines à vecteurs de support, efficace pour modéliser des relations complexes mais sensible au choix des paramètres.

Ces modèles ont été choisis afin de comparer différentes approches du machine learning, allant des méthodes simples aux méthodes plus avancées, et d'identifier le modèle le plus performant pour la prédiction de la performance académique.

VIII. Résultats expérimentaux

```
---- Linear Regression ----
MSE: 2.2043972043127016
RMSE: 1.4847212547521174
MAE: 0.9889415932251956
R2: 0.8187885745636069
MedAE: 0.6019277398823846
Explained Variance: 0.8239020360460756

---- Random Forest ----
MSE: 1.5524127659574463
RMSE: 1.245958573130522
MAE: 0.7034042553191489
R2: 0.8723846457278953
MedAE: 0.5199999999999996
Explained Variance: 0.872384883894016

---- Decision Tree ----
MSE: 1.4680851063829787
RMSE: 1.211645619140753
MAE: 0.7446808510638298
R2: 0.8793167609407562
MedAE: 1.0
Explained Variance: 0.880247097350402

---- SVR ----
MSE: 5.998644078033919
RMSE: 2.4492129507321163
MAE: 1.6058919414425832
R2: 0.5068843119835917
MedAE: 1.0344999440259652
Explained Variance: 0.5101924075662871
```

Fig. 7. Comparaison des modèles

Cette figure présente la comparaison des performances des différents modèles de régression utilisés dans ce travail. Les résultats montrent des différences significatives entre les modèles en termes de précision et de capacité de généralisation.

On remarque que le modèle **Decision Tree Regressor** obtient les meilleures performances avec un score R^2 élevé, ce qui indique une bonne capacité à expliquer la variance des données. Le modèle **Random Forest** donne également de bons résultats grâce à sa robustesse et à sa capacité à réduire le surapprentissage.

La **régression linéaire** offre des performances acceptables mais limitées, ce qui s'explique par sa difficulté à modéliser des relations non linéaires entre les variables. Enfin, le modèle **SVR** présente les performances les plus faibles sur ce dataset, ce qui peut être lié au choix des paramètres et à la sensibilité du modèle aux données.

Dans l'ensemble, les modèles basés sur les arbres de décision semblent plus adaptés à ce problème de prédiction de la performance académique.

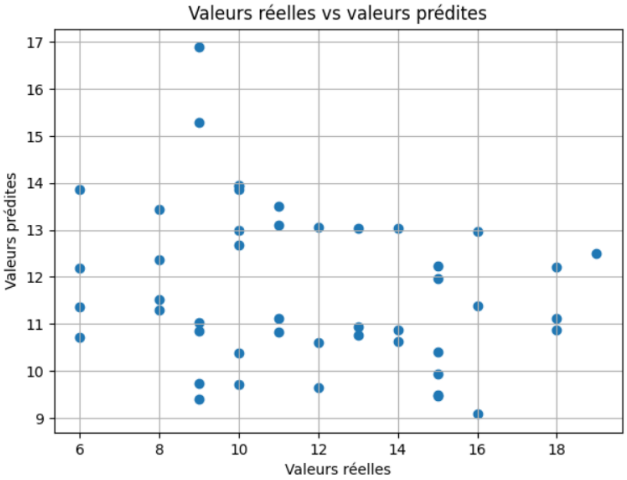

Fig. 8. Valeurs réelles vs valeurs prédites

IX. Discussion

Les résultats obtenus dans cette étude mettent en évidence l'impact du choix des modèles de machine learning sur la qualité des prédictions de la performance académique des étudiants. On observe que les performances varient significativement selon la capacité de chaque modèle à capturer la complexité des relations entre les variables.

Les modèles basés sur les arbres de décision, notamment le **Decision Tree Regressor** et le **Random Forest**, ont obtenu les meilleures performances. Cela s'explique par leur aptitude à modéliser des relations non linéaires et des interactions complexes entre les variables explicatives et la variable cible G3. En particulier, Random Forest améliore la stabilité des prédictions grâce à la combinaison de plusieurs arbres, ce qui réduit le surapprentissage et augmente la robustesse du modèle.

En revanche, la **régression linéaire** montre des performances plus limitées, car elle repose sur l'hypothèse d'une relation linéaire entre les variables. Cette hypothèse simplificatrice ne permet pas de capturer toute la complexité des données éducatives. De même, le modèle **SVR** présente des résultats moins performants, ce qui peut être attribué à la sensibilité du modèle aux paramètres ainsi qu'à la nécessité d'un réglage fin des hyperparamètres.

Par ailleurs, l'analyse des résultats montre également l'importance du prétraitement des données dans l'amélioration des performances globales. Les étapes telles que la normalisation, le traitement des valeurs aberrantes et le choix des variables influencent directement la qualité des modèles.

Enfin, cette étude confirme que les modèles d'ensemble et les approches basées sur les arbres sont généralement plus adaptés aux problèmes de prédiction dans le domaine éducatif, où les relations entre variables sont souvent complexes et non linéaires.

X. Conclusion

Dans ce travail, nous avons étudié la problématique de la prédiction de la performance académique des étudiants à l'aide de techniques de machine learning. L'objectif principal était de comparer plusieurs modèles de régression afin d'identifier celui qui permet de mieux prédire la note finale G3 à partir de variables académiques et sociales.

Tout au long de ce travail, plusieurs étapes ont été réalisées, notamment l'analyse exploratoire des données, le prétraitement, l'entraînement des modèles ainsi que leur évaluation à l'aide de différentes métriques de performance. Les résultats obtenus montrent clairement que les modèles basés sur les arbres de décision, en particulier le Decision Tree Regressor et le Random Forest, offrent les meilleures performances sur ce dataset.

Cette étude confirme également que la nature des données joue un rôle essentiel dans le choix du modèle. En effet, les relations non linéaires entre les variables rendent les modèles basés sur les arbres plus adaptés que les modèles linéaires comme la régression linéaire ou SVR.

Par ailleurs, les résultats soulignent l'importance des étapes de prétraitement et du choix des variables dans l'amélioration des performances globales des modèles. Une bonne préparation des données permet d'obtenir des prédictions plus stables et plus fiables.

Comme perspectives de ce travail, plusieurs améliorations peuvent être envisagées. Il serait intéressant d'appliquer des techniques d'optimisation des hyperparamètres afin d'améliorer encore les performances des modèles. L'utilisation de méthodes d'ensemble plus avancées telles que le stacking, ainsi que l'intégration de modèles de deep learning, pourrait également être explorée. Enfin, tester ces approches sur d'autres datasets permettrait de valider leur capacité de généralisation dans différents contextes éducatifs.

XI. Références

References

[1] UCI Machine Learning Repository, "Student Performance Dataset", 2014. https://archive.ics.uci.edu/

[2] Pedregosa, F. et al., "Scikit-learn: Machine Learning in Python", Journal of Machine Learning Research, 2011.

[3] Breiman, L., "Random Forests", Machine Learning, 2001.

[4] Quinlan, J. R., "Induction of Decision Trees", Machine Learning, 1986.

[5] Cortes, C. and Vapnik, V., "Support-vector networks", Machine Learning, 1995.

[6] James, G. et al., "An Introduction to Statistical Learning", Springer, 2013.

[7] Hastie, T., Tibshirani, R., Friedman, J., "The Elements of Statistical Learning", Springer, 2009.

[8] Alaa, A. M., "Machine Learning in Education: A Review", IEEE Access, 2020.

[9] Cortez, P. and Silva, A., "Using Data Mining to Predict Secondary School Student Performance", 2008.

[10] Kuhn, M., Johnson, K., "Applied Predictive Modeling", Springer, 2013.

[11] MDPI, "Student Performance Prediction Using Machine Learning", Applied Sciences Journal, 2020.

[12] Romero, C. and Ventura, S., "Educational Data Mining: A Review", IEEE Transactions on Systems, 2010.

[13] Zhang, H., "The Optimality of Naive Bayes", Florida AI Research Society, 2004.

[14] Goodfellow, I., Bengio, Y., Courville, A., "Deep Learning", MIT Press, 2016.

[15] Han, J., Kamber, M., Pei, J., "Data Mining: Concepts and Techniques", Elsevier, 2012.